

Geri Bildirim Tabanlı Müşteri Memnuniyeti Analizi: Türkçe Mobil Uygulama Yorumları Üzerinde Klasik Makine Öğrenmesi, Derin Öğrenme, Transformer ve Büyük Dil Modellerinin Karşılaştırmalı Değerlendirmesi

Furkan Öztürk
Kocaeli Üniversitesi
Yazılım Mühendisliği
230229083@kocaeli.edu.tr

Taha Yasin Çiçek
Kocaeli Üniversitesi
Yazılım Mühendisliği
230229088@kocaeli.edu.tr

Ziyaeddin Ayerden
Kocaeli Üniversitesi
Yazılım Mühendisliği
210229022@kocaeli.edu.tr

Özetçe Bu çalışmada, App Store ve Google Play platformlarından toplanan Türkçe mobil uygulama yorumları üzerinde müşteri memnuniyetinin (pozitif, nötr, negatif) otomatik olarak sınıflandırılması amaçlanmaktadır. Altı farklı kategoride (sosyal medya, e-ticaret, yemek, süpermarket, kariyer ve bankacılık) yer alan 55 uygulamaya ait toplam 69.002 temizlenmiş yorum üzerinde, yıldız derecelendirmesi ile büyük dil modelini (Grok Llama 3.1) birleştiren melez (hibrit) bir etiketleme stratejisi uygulanmıştır. Klasik makine öğrenmesi (TF-IDF + Lojistik Regresyon, Destek Vektör Makineleri), derin öğrenme (TextCNN, Dikkat mekanizmalı Çift Yönlü LSTM), önceden eğitilmiş Türkçe BERT ve sıfır-atış (zero-shot) bir büyük dil modeli (Llama 3.3 70B) karşılaştırmalı olarak değerlendirilmiştir. Klasik TF-IDF + Lojistik Regresyon modeli, test kümesinde %68,87 doğruluk ve %66,91 F1 skoru ile derin öğrenme yaklaşımlarını geride bırakmış; sıfır-atış Llama 3.3 70B ise küçük bir alt kümede %82 doğruluk elde etmiştir. Sonuçlar, Streamlit tabanlı etkileşimli bir arayüz üzerinden altı modelin karşılaştırılması, BERT dikkat görselleştirmesi, firma bazında yorum özetleri, kelime bulutları ve TF-IDF kelime analizi olarak sunulmaktadır.

Anahtar Kelimeler duygu analizi, müşteri memnuniyeti, metin sınıflandırma, TF-IDF, BERT, büyük dil modelleri, Türkçe doğal dil işleme, mobil uygulama yorumları

I. GİRİŞ

Mobil uygulama mağazalarındaki kullanıcı yorumları, ürün ve hizmetlere ilişkin müşteri memnuniyetinin en geniş ölçekli ve güncel kaynaklarından biridir [1]. Ancak bu geri bildirimlerin manuel olarak incelenmesi, hacim ve hız nedeniyle pratik değildir; bu nedenle metinden otomatik duygu çıkarımı (duygu analizi / fikir madenciliği) hem akademide hem de endüstride önemli bir araştırma alanı haline gelmiştir [2], [3], [4].

Bu çalışmanın temel araştırma sorusu şudur: Türkçe mobil uygulama yorumlarından müşteri memnuniyeti seviyesi (pozitif/nötr/negatif) ne kadar doğru tahmin edilebilir ve farklı model aileleri bu görevde nasıl bir başarımlar sergiler? Türkçe, sondan eklemeli (aglutinatif) yapısı ve zengin biçim bilgisi nedeniyle doğal dil işleme açısından zorlu bir dildir ve özel-

likle kısa, günlük dile dayanan uygulama yorumlarında yazım hataları, kısaltmalar ve emoji kullanımı yaygındır.

Bu çalışmanın başlıca katkıları şunlardır:

- Altı kategoride 55 uygulamadan iki ayrı platform (App Store ve Google Play) üzerinden toplanan ve temizlenen 69.002 yorumdan oluşan özgün bir Türkçe veri kümesi.
- Yıldız derecelendirmesi kuralları ile büyük dil modeli düzeltmesini birleştiren melez (hibrit) bir etiketleme stratejisi.
- Klasik ML, derin öğrenme, transformer ve büyük dil modellerinin aynı veri kümesi üzerinde adil ve sistematik karşılaştırılması.
- Altı modeli, BERT dikkat görselleştirmesini ve kelime analizlerini bir araya getiren, Streamlit tabanlı etkileşimli bir kullanıcı arayüzü.

Makalenin geri kalanı şu şekilde düzenlenmiştir: Bölüm II ilgili çalışmaları, Bölüm III veri kümesini, Bölüm IV yöntemi, Bölüm V deneysel sonuçları, Bölüm VI etkileşimli arayüzü, Bölüm VII tartışmayı ve Bölüm VIII sonuçları sunar.

II. İLGİLİ ÇALIŞMALAR

Duygu analizi alanındaki temel araştırmalar, fikir madenciliğinin kuramsal çerçevesini ortaya koymuştur [2], [3]; Medhat ve diğerleri ise alandaki algoritma ve uygulamaları kapsamlı bir derlemede toplamıştır [4]. Metin temsili açısından terim ağırlıklandırması (TF-IDF) klasik bir temel oluşturmada [5], [6], Destek Vektör Makineleri ise metin sınıflandırmada uzun süre referans yöntem olarak kullanılmıştır [7], [8].

Dağıtık kelime temsillerinin (word embedding) geliştirilmesi [9] ve duygu analizine özgü kelime vektörlerinin öğrenilmesi [10] derin öğrenme tabanlı metin sınıflandırmanın önünü açmış; evrimsel sinir ağlarının cümle sınıflandırmada etkinliği gösterilmiş [11], uzun-kısa süreli bellek (LSTM) ağları dizesel bağımlılıkları modellemek için kullanılmıştır [12]. Dikkat (attention) mekanizması [13] ve Transformer mimarisi [14] ile birlikte, BERT gibi önceden eğitilmiş

dil modelleri pek çok doğal dil işleme görevinde son teknoloji sonuçlar elde etmiştir [15]. Türkçe için ise BERTurk modelleri [16] ve SentiTurkNet gibi kutupluluk sözlükleri [17] geliştirilmiştir.

Son dönemde, GPT-3 ile popülerleşen az-atış/sıfır-atış öğrenme [18] ve açık ağırlıklı LLaMA ailesi [19], [20], etiketli veriye ihtiyaç duymadan sınıflandırma yapabilme imkanı sunmuştur. Mobil uygulama yorumlarından fikir madenciliği özelinde ise Pagano ve Maalej kullanıcı geri bildirimlerinin ampirik bir incelemesini sunmuş [1], Genç-Nayebi ve Abran ise alandaki çalışmaları sistematik bir literatür taramasıyla özetlemiştir [21]. Bu çalışma, anılan model ailelerinin tümünü tek bir Türkçe veri kümesi üzerinde karşılaştırarak ve etkileşimli bir arayüze dönüştürerek literatüre katkı sağlar.

III. VERİ KÜMESİ

A. Veri Toplama (Scraping)

Veriler iki kaynaktan otomatik olarak çekilmiştir: Google Play ve Apple App Store (ülke: Türkiye, tr). Altı kategoride toplam 55 popüler uygulama hedeflenmiş; her uygulama için Google Play paket adı ve App Store sayısal kimliği kullanılmıştır. Kategorilere göre uygulama dağılımı Şekil 2’de verilmiştir.

B. Ön İşleme ve Temizleme

Ham yorumlar şu adımlardan geçirilmiştir: (i) Unicode NFC normalleştirme; (ii) görünmez karakterlerin (sıfır genişlikli boşluk, BOM) temizlenmesi; (iii) ardışık boşlukların tek boşluğa indirgenmesi ve kırılması; (iv) boş metinlerin elenmesi; (v) derecelendirmenin 1-5 aralığına doğrulanması; (vi) tarihlerin ayrıştırılması ve geçersizlerin elenmesi; (vii) yinelenen kayıtların önce `review_id`, ardından [platform, yazar, metin] kombinasyonuna göre kaldırılması. Bu işlemler sonucunda 69.002 temiz yorum elde edilmiştir.

C. Melez (Hibrit) Etiketleme

Müşteri memnuniyeti üç sınıfa indirgenmiştir: yıldız ≤ 2 ise negatif, $= 3$ ise nötr, ≥ 4 ise pozitif. Ancak metin ile puanın çeliştiği durumlar (örneğin düşük puanlı ama olumlu ifadeler içeren bir yorum) bir kural tabanı ile tespit edilmiş, bu çelişkili yorumlar Groq API [22] üzerinden llama-3.1-8b-instant büyük dil modeline (20’şerlik gruplar, sıcaklık 0,0) yeniden etiketlenmiştir. Model çağrısı başarısız olan durumlarda yıldız tabanına geri dönmüştür. Elde edilen sınıf dağılımı Şekil 1’de özetlenmiştir.

IV. YÖNTEM

Çalışmada dört model ailesi değerlendirilmiştir. Sistemin genel akışı Şekil 3’de gösterilmektedir. Tüm modeller, %80/%20 oranında ve sınıf dağılımı korunarak (stratified) ayrılan eğitim/test bölünmesi üzerinde değerlendirilmiştir.

TABLE I: Veri Kümesi Özeti

Özellik	Değer
Toplam temiz yorum	69.002
Google Play kaynaklı	49.699
App Store kaynaklı	19.303
Benzersiz uygulama sayısı	55
Kategori sayısı	6
Negatif yorum	30.278
Pozitif yorum	27.760
Nötr yorum	10.964




Fig. 1: Veri kümesinin sınıf (a) ve platform (b) bazında dağılımı.




Fig. 2: Kategori bazında uygulama sayısı (toplam 55 uygulama, 6 kategori).

A. Klasik Makine Öğrenmesi

Metinler, en fazla 50.000 öznitelik, (1, 3) n-gram aralığı, alt-doğrusal terim frekansı (sublinear TF) ve aksan sadeleştirme kullanılarak TF-IDF ile vektörleştirilmiştir [6], [5]. Üzerine iki klasik sınıflandırıcı eğitilmiştir: (i) Lojistik




Fig. 3: Sistemin uçtan uca iş akışı.

TABLE II: Modellerin Temel Hiperparametreleri

Model	Yapılandırma
TF-IDF	50.000 öznitelik, (1,3) n-gram, sublinear TF
Loj. Regresyon	$C=5,0$, lbfgs, max_iter 1000
LinearSVC	$C=1,0$, squared_hinge
TextCNN	filtreler (2,3,4,5)×128, dropout 0,3
Bi-LSTM+Dikkat	128 gizli birim, 2 katman, dropout 0,3
Ortak (DL)	gömme 128, dizi 200, yığın 64, 10 dönem, lr 10^{-3}

Regresyon ($C=5,0$, lbfgs çözücü, en fazla 1000 yineleme) ve (ii) Doğrusal Destek Vektör Makinesi (LinearSVC, $C=1,0$, squared_hinge kaybı) [7], [8].

B. Derin Öğrenme

İki derin öğrenme modeli, ortak hiperparametrelerle (kelime dağarcığı 30.000, gömme boyutu 128, en fazla dizi uzunluğu 200, yığın boyutu 64, 10 dönem, öğrenme oranı 10^{-3} , Adam eniyileyici, ReduceLROnPlateau çizelgeleme ve 1.0 gradyan kırpması) eğitilmiştir:

- TextCNN [11]: (2, 3, 4, 5) filtre boyutları, boyut başına 128 filtre, küresel maksimum havuzlama ve 0,3 dropout.
- Dikkat mekanizmalı Çift Yönlü LSTM [12], [13]: 128 gizli birim, 2 katman, çift yönlü, toplamsal (Bahdanau tipi) dikkat ile ağırlıklı bağlam vektörü.

C. Türkçe BERT

Etkileşimli arayüz için, önceden eğitilmiş bir Türkçe BERT modeli (savasy/bert-base-turkish-sentiment-cased) Hugging Face üzerinden kullanılmıştır [15], [16], [23]. Modelin son katmanındaki dikkat ağırlıkları, başlar üzerinde ortalama alınarak ve alt-kelime parçaları birleştirilerek hangi kelimelerin karara etki ettiğini gösteren bir görselleştirmeye dönüştürülmüştür.

D. Büyük Dil Modeli (Sıfır-Atış)

Etiketli veriyle eğitim yapılmadan, Groq API üzerinden llama-3.3-70b-versatile modeline sıfır-atış bir komut verilerek (sıcaklık 0,0) test kümesinden rastgele seçilen 50 örnek sınıflandırılmıştır [18], [20]. Model, yalnızca pozitif, nötr veya negatif etiketlerinden birini döndürmeye yönlendirilmiştir.

Modellerin eğitiminde scikit-learn [24], PyTorch [25] ve Hugging Face Transformers [23] kütüphaneleri kullanılmıştır. Temel hiperparametreler Tablo II’de özetlenmiştir.

V. DENEYSEL SONUÇLAR

Dört temel modelin test kümesi sonuçları Tablo III ve Şekil 4’de sunulmaktadır. Beklenenin aksine, klasik TF-IDF + Lojistik Regresyon modeli (%68,87 doğruluk, %66,91 F1), derin öğrenme modellerinin tümünü geride bırakmıştır. Bunun

TABLE III: Test Kümesinde Model Karşılaştırması (%)

Model	Doğ.	Kesinlik	Duyarlılık	F1
Loj. Regresyon	68,87	66,00	68,87	66,91
SVM (LinearSVC)	68,42	65,47	68,42	66,42
TextCNN	67,36	64,06	67,36	65,11
Bi-LSTM + Dikkat	65,23	63,56	65,23	64,29




Fig. 4: Temel modellerin doğruluk ve F1 skoru karşılaştırması.

TABLE IV: Sıfır-Atış Llama 3.3 70B - Sınıf Bazında Sonuçlar (50 örnek)

Sınıf	Kesinlik	Duyarlılık	F1	Destek
Negatif	0,73	1,00	0,85	22
Nötr	1,00	0,40	0,57	5
Pozitif	0,94	0,74	0,83	23
Genel doğruluk				0,82

A. Sıfır-Atış LLM Değerlendirmesi


Sıfır-atış Llama 3.3 70B modeli, 50 örnekten oluşan küçük bir alt kümede %82 doğruluk elde etmiştir. Sınıf bazındaki sonuçlar Tablo IV ve Şekil 5’de verilmiştir. Model, negatif sınıfı yüksek duyarlılıkla yakalarken nötr sınıfta düşük duyarlılık sergilemiştir; bu durum nötr sınıfın doğası gereği belirsiz olmasıyla uyumludur. Not: bu sonuç yalnızca 50 örnek üzerinden elde edildiğinden, doğrudan dört temel modelle kıyaslanmamalı, yalnızca yol gösterici bir gösterge olarak değerlendirilmelidir.

VI. ETKİLEŞİMLİ ARAYÜZ


Modeller ve analizler, Streamlit [26] ve Plotly ile geliştirilen, dört sekmeli etkileşimli bir web uygulaması üzerinden sunulmaktadır. Şekil 6 arayüzün genel görünümünü ve Duygu Testi sekmesini, Şekil 7 ise Firma Arama sekmesini göstermektedir. Kelime Bulutu ve TF-IDF tabanlı Kelime Analizi sekmelerinin çıktıları ise Şekil 8 ve Şekil 9’da sunulmaktadır.

başlıca nedenleri; veri kümesinin boyutunun (yaklaşık 69 bin) sıfırdan eğitilen derin ağlar için nispeten sınırlı olması, n-gram tabanlı TF-IDF öznitelik uzayının kısa yorum metinlerinde güçlü bir temel oluşturması ve sınıf dengesizliğidir.


Olumlu Yorumlarda Öne Çıkan Kelimeler



Nötr Yorumlarda Öne Çıkan Kelimeler



Olumsuz Yorumlarda Öne Çıkan Kelimeler



Şekil 9: Sınıf bazında en yüksek TF-IDF ağırlıklı kelimeler (yukarıdan aşağıya: olumlu, nötr ve olumsuz).

VII. TARTIŞMA

Bulgular, kısa ve gürültülü uygulama yorumlarında iyi ayarlanmış klasik bir TF-IDF + Lojistik Regresyon temelini, sınırlı veri ile sıfırdan eğitilen derin ağlara kıyasla rekabetçi, hatta üstün olabileceğini göstermektedir. Sıfır-atış LLM sonuçları umut verici olmakla birlikte, yalnızca 50 örnek üzerinde ölçüldüğü için kesin bir üstünlük iddiası için yeterli değildir. Çalışmanın başlıca sınırlılıkları; (i) etiketlerin kısmen

REFERENCES

- [1] D. Pagano and W. Maalej, "User feedback in the appstore: An empirical study," in Proc. 21st IEEE Int. Requirements Engineering Conf. (RE), Rio de Janeiro, Brazil, 2013, pp. 125-134, doi: 10.1109/RE.2013.6636712.
- [2] B. Pang and L. Lee, "Opinion mining and sentiment analysis," Foundations and Trends in Information Retrieval, vol. 2, no. 1-2, pp. 1-135, 2008, doi: 10.1561/1500000011.
- [3] B. Liu, Sentiment Analysis and Opinion Mining (Synthesis Lectures on Human Language Technologies, vol. 5, no. 1). San Rafael, CA, USA: Morgan & Claypool, 2012, pp. 1-167, doi: 10.2200/S00416ED1V01Y201204HLT016.
- [4] W. Medhat, A. Hassan, and H. Korashy, "Sentiment analysis algorithms and applications: A survey," Ain Shams Engineering Journal, vol. 5, no. 4, pp. 1093-1113, 2014, doi: 10.1016/j.asej.2014.04.011.
- [5] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," Journal of Documentation, vol. 28, no. 1, pp. 11-21, 1972, doi: 10.1108/eb026526.
- [6] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," Information Processing & Management, vol. 24, no. 5, pp. 513-523, 1988, doi: 10.1016/0306-4573(88)90021-0.
- [7] C. Cortes and V. Vapnik, "Support-vector networks," Machine Learning, vol. 20, no. 3, pp. 273-297, 1995, doi: 10.1007/BF00994018.
- [8] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in Proc. 10th Eur. Conf. Machine Learning (ECML-98), LNCS vol. 1398. Berlin, Germany: Springer, 1998, pp. 137-142, doi: 10.1007/BFb0026683.
- [9] T. Mikolov, K. Chen, G. Corrado, and J. Dean, "Efficient estimation of word representations in vector space," in Proc. Int. Conf. Learning Representations (ICLR) Workshop, Scottsdale, AZ, USA, 2013, arXiv:1301.3781.
- [10] A. L. Maas, R. E. Daly, P. T. Pham, D. Huang, A. Y. Ng, and C. Potts, "Learning word vectors for sentiment analysis," in Proc. 49th Annu. Meeting Assoc. Comput. Linguistics: Human Language Technologies (ACL-HLT), Portland, OR, USA, 2011, pp. 142-150.
- [11] Y. Kim, "Convolutional neural networks for sentence classification," in Proc. 2014 Conf. Empirical Methods in Natural Language Processing (EMNLP), Doha, Qatar, 2014, pp. 1746-1751, doi: 10.3115/v1/D14-1181.
- [12] S. Hochreiter and J. Schmidhuber, "Long short-term memory," Neural Computation, vol. 9, no. 8, pp. 1735-1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [13] D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate," in Proc. 3rd Int. Conf. Learning Representations (ICLR), San Diego, CA, USA, 2015, arXiv:1409.0473.
- [14] A. Vaswani et al., "Attention is all you need," in Advances in Neural Information Processing Systems 30 (NIPS), Long Beach, CA, USA, 2017, pp. 5998-6008.
- [15] S. Schweter, "BERTurk – Bert models for Turkish," Zenodo, Apr. 2020, doi: 10.5281/zenodo.3770924.
- [16] R. Dehkharghani, Y. Saygın, B. Yanıkoğlu, and K. Oflazer, "Senti-TurkNet: A Turkish polarity lexicon for sentiment analysis," Language Resources and Evaluation, vol. 50, no. 3, pp. 667-685, 2016, doi: 10.1007/s10579-015-9307-6.
- [17] T. B. Brown et al., "Language models are few-shot learners," in Advances in Neural Information Processing System 33 /NeurIPS), 2020, pp. 1877-1901.
- [18] H. Touvron et al., "LLaMA: Open and efficient foundation language models," arXiv:2302.13971, 2023, doi: 10.48550/arXiv.2302.13971.
- [19] A. Grattafiori et al. (Llama Team, Meta AI), "The Llama 3 herd of models," arXiv:2407.21783, 2024, doi: 10.48550/arXiv.2407.21783.
- [20] N. Genc-Nayebi and A. Abran, "A systematic literature review: Opinion mining studies from mobile app store user reviews," Journal of Systems and Software, vol. 125, pp. 207-219, 2017, doi: 10.1016/j.jss.2016.11.027.
- [21] Groq, Inc., "GroqCloud documentation," 2026. [Online]. Available: <https://cosole.groq.com/docs> (Erişim: Haz. 2026).
- [22] T. Wolf et al., "Transformers: State of the art natural language processing," in Proc. 2020 Conf. Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP), Online, 2020, pp. 38-45, doi: 10.18653/v1/2020.emnlp-demos.6.
- [23] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825-2830, 2011.
- [24] A. Paszke et al., "PyTorch: An imperative style, high performance deep learning library," in Advances in Neural Information Processing Systems 32 (NeurIPS), Vancouver, Canada, 2019, pp. 8024-8035.
- [25] Streamlit Inc., "A faster way to build and share data apps," 2026. [Online]. Available: <https://streamlit.io> (Erişim: Haz. 2026).